

ΑΡΙΣΤΟΤΕΛΕΙΟ ΠΑΝΕΠΙΣΤΗΜΙΟ ΘΕΣΣΑΛΟΝΙΚΗΣ

Τμήμα Πληροφορικής

Εργασία στο Μάθημα


Υπολογιστική Νοημοσύνη – Βαθιά Ενισχυτική Μάθηση

Επίλυση του CartPole-v1 με Deep Q-Network (DQN)

Φοιτητής: Λιάτσος Γρηγόρης
Α.Ε.Μ.:4540

Υπεύθυνος Καθηγητής: Τέφας Αναστάσιος
Εαρινό Εξάμηνο 2025–2026

Ημερομηνία Υποβολής: 23/05/2026



CartPole-v1

Εξισορρόπηση εκκρεμούς με Βαθιά Ενισχυτική Μάθηση

Περιεχόμενα

1. Περιγραφή του Προβλήματος.....	3
1.1 Περιβάλλον CartPole-v1	3
1.2 Χώρος Κατάστασης και Δράσεων.....	3
2. Αρχιτεκτονική Δικτύου και Αλγόριθμος	4
2.1 Deep Q-Network (DQN)	4
2.2 Double DQN.....	5
2.3 Βασικά Τεχνικά Χαρακτηριστικά	5
3. Πειράματα και Αποτελέσματα.....	6
3.1 Μεθοδολογία Αξιολόγησης	6
3.2 Επίδραση Learning Rate	6
3.3 Επίδραση Μεγέθους Κρυφών Επιπέδων.....	7
3.4 Επίδραση Epsilon Decay.....	9
4. Τελικό Μοντέλο	11
4.1 Σύγκριση Υπερπαραμέτρων (Φάση Πειραμάτων).....	11
4.2 Ανάλυση Σύγκλισης Τελικού Μοντέλου.....	11
4.3 Αποτελέσματα Τελικού Μοντέλου	12
4.4 Αξιολόγηση Μοντέλου (Demonstration Results)	14
5. Οδηγίες Εκτέλεσης.....	15
5.1 Απαιτήσεις Συστήματος.....	15
5.2 Αναπαραγωγιμότητα Πειραμάτων	15
5.3 Εγκατάσταση.....	15
5.4 Εκτέλεση Εκπαίδευσης.....	15
5.5 Εκτέλεση Επίδειξης	16
6. Συμπεράσματα.....	16
6.1 Περιορισμοί της Προσέγγισης.....	17
7. Βιβλιογραφία.....	17

1. Περιγραφή του Προβλήματος

1.1 Περιβάλλον CartPole-v1

Το CartPole-v1 είναι ένα κλασικό πρόβλημα ελέγχου που ανήκει στη βιβλιοθήκη Gymnasium (πρώην OpenAI Gym). Το περιβάλλον αποτελείται από ένα καρότσι που κινείται πάνω σε οριζόντια ράγα, πάνω στο οποίο ισορροπεί ένα κατακόρυφο εκκρεμές. Στόχος του συστήματος είναι να διατηρηθεί το εκκρεμές σε κατακόρυφη θέση, εφαρμόζοντας κατάλληλες οριζόντιες δυνάμεις στο καρότσι.

1.2 Χώρος Κατάστασης και Δράσεων

Ο χώρος κατάστασης (*state space*) του περιβάλλοντος είναι συνεχής και αποτελείται από 4 φυσικές μεταβλητές:

Μεταβλητή	Περιγραφή	Εύρος Τιμών
x	Θέση καροτσιού	$[-4.8, 4.8]$ -Τερματισμός ± 2.4
$\dot{x}$	Ταχύτητα καροτσιού	$(-\infty, +\infty)$
θ	Γωνία εκκρεμούς	$[-0.209 \text{ rad}, 0.209 \text{ rad}]$
$\dot{\theta}$	Γωνιακή ταχύτητα	$(-\infty, +\infty)$

Ο χώρος δράσεων (*action space*) είναι διακριτός και περιλαμβάνει δύο δυνατές επιλογές για την κίνηση του καροτσιού:

- 0: Ώθηση του καροτσιού προς τα αριστερά.
- 1: Ώθηση του καροτσιού προς τα δεξιά.


Ο πράκτορας λαμβάνει θετική ανταμοιβή +1 για κάθε χρονικό βήμα (*time step*) κατά το οποίο το εκκρεμές παραμένει όρθιο. Το επεισόδιο τερματίζεται αμέσως εάν η γωνία του εκκρεμούς θ ξεπεράσει τις $\pm 12^\circ$ ($\pm 0.209 \text{ rad}$), εάν η θέση του καροτσιού x ξεπεράσει τα ± 2.4 μετατοπιζόμενο εκτός των ασφαλών ορίων της ράγας, ή εάν συμπληρωθούν επιτυχώς 500 χρονικά βήματα, οπότε και επιτυγχάνεται η μέγιστη δυνατή ανταμοιβή (Reward = 500).

2. Αρχιτεκτονική Δικτύου και Αλγόριθμος

2.1 Deep Q-Network (DQN)

Για την επίλυση του προβλήματος χρησιμοποιήθηκε ένα Multi-Layer Perceptron (MLP), το οποίο αποτελεί μια πλήρως συνδεδεμένη νευρωνική αρχιτεκτονική, κατάλληλη για διανυσματικές εισόδους. Η επιλογή του MLP είναι απολύτως επαρκής για το περιβάλλον CartPole, καθώς ο χώρος κατάστασης είναι ήδη χαμηλοδιάστατος (4 αριθμητικές τιμές) και δεν απαιτεί εξαγωγή οπτικών χαρακτηριστικών (όπως ένας CNN) ή μοντελοποίηση ακολουθιών (όπως ένας RNN/Transformer).

Η δομή του δικτύου που υλοποιήθηκε είναι η εξής:



Στρώμα	Τύπος	Παράμετροι
Είσοδος	Linear(4 → 128)	Συνάρτηση ενεργοποίησης ReLU
Κρυφό 1	Linear(128 → 128)	Συνάρτηση ενεργοποίησης ReLU
Έξοδος	Linear(128 → 2)	Q-values δράσεων (χωρίς συνάρτηση ενεργοποίησης)

2.2 Double DQN

Στην εργασία υλοποιήθηκε η παραλλαγή Double DQN (DDQN) με σκοπό την αντιμετώπιση του προβλήματος συστηματικής υπερεκτίμησης των τιμών Q (*overestimation bias*), το οποίο εμφανίζεται συχνά στον κλασικό αλγόριθμο DQN.

Η βασική διαφοροποίηση έγκειται στο ότι το τρέχον δίκτυο (*Policy Network*) χρησιμοποιείται αποκλειστικά για την επιλογή της βέλτιστης επόμενης δράσης, ενώ το δίκτυο-στόχος (*Target Network*) χρησιμοποιείται για την αριθμητική αξιολόγηση της αξίας της δράσης αυτής. Η μαθηματική διατύπωση του στόχου (*TD Target*) διαμορφώνεται ως εξής:

$$Y_t^{DoubleQ} = R_{t+1} + \gamma Q(S_{t+1}, \operatorname{argmax}_a Q(S_{t+1}, a; \theta_t); \theta_t^-)$$

Όπου θ_t αναπαριστά τις παραμέτρους του δικτύου πολιτικής και θ_t^- τις παραμέτρους του δικτύου-στόχου. Με τον διαχωρισμό αυτό, ο πράκτορας αποφεύγει τις αστάθειες και επιτυγχάνει πιο στιβαρή σύγκλιση.

2.3 Βασικά Τεχνικά Χαρακτηριστικά

Τεχνική	Περιγραφή
Experience Replay	Αποθήκευση των μεταβάσεων (s, a, r, s') σε έναν buffer χωρητικότητας 10.000 θέσεων. Η τυχαία δειγματοληψία (<i>mini-batch</i>) σπάει τις χρονικές συσχετίσεις των δεδομένων εκπαίδευσης.
Target Network	Χρήση ενός ανεξάρτητου δικτύου στόχου που παραμένει σταθερό και ενημερώνεται περιοδικά κάθε 1.000 βήματα, εξασφαλίζοντας σταθερότητα κατά την εκπαίδευση.
e-Greedy Policy	Στρατηγική εξερεύνησης με εκθετική μείωση της παραμέτρου ϵ από 1.0 έως το ελάχιστο όριο 0.05. Ο ρυθμός μείωσης καθορίζεται από την υπερπαραμέτρο <i>Epsilon Decay</i> .
Huber Loss	Χρήση της συνάρτησης απώλειας Smooth L1 αντί της MSE, προσφέροντας μικρότερη ευαισθησία σε ακραίες τιμές (<i>outliers</i>) όταν τα σφάλματα είναι μεγάλα.
Gradient Clipping	Περιοπή των κλίσεων (<i>gradients</i>) με κατώφλι (threshold) το 10, για την αποφυγή του φαινομένου έκρηξης κλίσεων (<i>exploding gradients</i>).
Optimizer	Χρήση του αλγορίθμου Adam για τη δυναμική προσαρμογή του ρυθμού μάθησης ανά παράμετρο.

3. Πειράματα και Αποτελέσματα

3.1 Μεθοδολογία Αξιολόγησης

Για την εύρεση του βέλτιστου συνδυασμού υπερπαραμέτρων, ακολουθήθηκε μια μεθοδολογία ελεγχόμενων δοκιμών 3 φάσεων. Σε κάθε φάση μεταβάλλεται μία συγκεκριμένη υπερπαραμέτρος, ενώ οι υπόλοιπες κρατούνται σταθερές στις βασικές τους τιμές ($lr = 10^{-4}$, Hidden Size = 128, Epsilon Decay = 600), με σκοπό την απομόνωση και την ακριβή αξιολόγηση της επίδρασής της στη διαδικασία μάθησης.

Όλα τα προκαταρκτικά πειράματα εκτελέστηκαν για **280 επεισόδια** προκειμένου να αποτυπωθεί η αρχική τάση σύγκλισης, ενώ το τελικό μοντέλο εκπαιδεύτηκε εκτενώς για **800 επεισόδια**.

Ο προγραμματισμός των πειραμάτων αποτυπώνεται στον παρακάτω πίνακα:

Φάση Πειράματος	Μεταβαλλόμενη Υπερπαραμέτρος	Δοκιμαζόμενες Τιμές	Σταθερές Παράμετροι Φάσης
3.1	Ρυθμός Μάθησης (Learning Rate)	0.01, 0.001, 0.0001	Hidden Size = 128, Epsilon Decay = 600
3.2	Μέγεθος Κρυφών Επιπέδων (Hidden Size)	64, 128, 256	Learning Rate = 0.0001, Epsilon Decay = 600
3.3	Ρυθμός Μείωσης Εξερεύνησης (Epsilon Decay)	100, 300, 600	Learning Rate = 0.0001, Hidden Size = 128

3.2 Επίδραση Learning Rate

Learning Rate	Καλύτερο Σκορ	Μέσος Όρος	Last-20 Avg	Αξιολόγηση
0.01	43	13,2	14,2	Αστάθεια
0.001	41	12,3	17,3	Περιορισμένη σύγκλιση
0.0001	500	106,0	221,8	Βέλτιστο – σταθερή βελτίωση


Ο ρυθμός μάθησης (*learning rate* - *lr*) αποτελεί μία από τις κρίσιμότερες υπερπαραμέτρους, καθώς καθορίζει το μέγεθος των βημάτων διόρθωσης των βαρών του νευρωνικού δικτύου προς την κατεύθυνση μείωσης του σφάλματος. Όπως προκύπτει από τα πειραματικά αποτελέσματα, η επιλογή του $lr = 0.0001$ (10^{-4}) παρουσίασε με διαφορά την καλύτερη και πιο σταθερή συμπεριφορά, επιτυγχάνοντας μέγιστο σκορ 500 και μέσο όρο των τελευταίων 20 επεισοδίων ίσο με 221,8.

Στο Σχήμα 1 παρατηρείται ότι με $lr = 0.0001$ ο πράκτορας διατηρεί χαμηλές πειραματικές επιδόσεις κατά τα πρώτα 230 επεισόδια. Η συμπεριφορά αυτή είναι απόλυτα φυσιολογική και οφείλεται στην εκτενή εξερεύνηση (*exploration*) που πραγματοποιείται στα αρχικά στάδια της εκπαίδευσης. Ωστόσο, η χαμηλή τιμή του ρυθμού μάθησης επέτρεψε στο δίκτυο να «χτίσει» σταθερές και στιβαρές βάσεις γνώσης χωρίς να καταστρέφει τις νευρωνικές του συνδέσεις. Έτσι, μόλις η παράμετρος εξερεύνησης μειώθηκε επαρκώς (μετά το επεισόδιο 230 ο πράκτορας πέρασε σταδιακά στη φάση της εκμετάλλευσης (*exploitation*), παρουσιάζοντας σταθερή σύγκλιση προς υψηλότερες τιμές ανταμοιβής

Αντίθετα, οι υψηλότεροι ρυθμοί μάθησης δεν οδήγησαν σε σταθερή σύγκλιση:

- Με $lr = 0.01$, οι υπερβολικά μεγάλες ενημερώσεις στα βάρη οδήγησαν σε έντονη αστάθεια κατά την εκπαίδευση, εγκλωβίζοντας τον πράκτορα σε σχεδόν τυχαίες κινήσεις με μέγιστο σκορ μόλις 43.
- Με $lr = 0.001$, το μοντέλο παρουσίασε περιορισμένη βελτίωση χωρίς σταθερή σύγκλιση. Παρά τις προσωρινές αυξήσεις της ανταμοιβής σε ορισμένα επεισόδια, το δίκτυο εμφάνισε σημαντική αστάθεια κατά την εκπαίδευση, επιβεβαιώνοντας ότι οι μεγάλες διορθώσεις των

βαρών σε προβλήματα ενισχυτικής μάθησης μπορούν να οδηγήσουν σε φαινόμενα καταστροφικής λήθης (catastrophic forgetting).



Σχήμα 1: Καμπύλη επιδόσεων για $lr=0.0001$ (βέλτιστο learning rate)


3.3 Επίδραση Μεγέθους Κρυφών Επιπέδων

Hidden Size	Καλύτερο Σκορ	Μέσος Όρος	Last-20 Avg	Αξιολόγηση
64	44	11.5	12.3	Underfitting – ανεπαρκής χωρητικότητα
128	53	12.9	14.4	Οριακά καλύτερη σταθερότητα
256	47	11.9	15.5	Υψηλή αστάθεια εκπαίδευσης

Το μέγεθος των κρυφών επιπέδων (*hidden size*) καθορίζει την εκφραστική ικανότητα (*capacity*) του νευρωνικού δικτύου, δηλαδή το πόσο σύνθετες συναρτήσεις Q μπορεί να προσεγγίσει. Με βάση τις δοκιμές, η αρχιτεκτονική με **128 νευρώνες** ανά κρυφό επίπεδο παρουσίασε οριακά καλύτερη και πιο σταθερή συμπεριφορά σε σχέση με τις υπόλοιπες διαμορφώσεις, επιτυγχάνοντας μέγιστο σκορ 53 και Last-20 Avg ίσο με 14.4.

Η ανάλυση των αποτελεσμάτων για τις τρεις διαμορφώσεις αναδεικνύει τα εξής συμπεράσματα:

- **Μικρή χωρητικότητα (64 νευρώνες):** Το δίκτυο παρουσίασε έντονο φαινόμενο υποπροσαρμογής (*underfitting*). Ο περιορισμένος αριθμός παραμέτρων αποδείχθηκε ανεπαρκής για να χαρτογραφήσει με ακρίβεια τις μη γραμμικές σχέσεις μεταξύ των τεσσάρων μεταβλητών του χώρου κατάστασης, με αποτέλεσμα ο πράκτορας να μην μπορεί να σταθεροποιήσει το εκκρεμές και να περιοριστεί σε μέγιστο σκορ μόλις 47.
- **Βέλτιστη χωρητικότητα (128 νευρώνες):** Η διαμόρφωση με 128 νευρώνες παρουσίασε οριακά καλύτερη συμπεριφορά σε σχέση με τις υπόλοιπες αρχιτεκτονικές, επιτυγχάνοντας το υψηλότερο μέγιστο σκορ και ελαφρώς αυξημένο μέσο όρο ανταμοιβής. Παρότι δεν παρατηρήθηκε πλήρης σύγκλιση, το δίκτυο εμφάνισε πιο σταθερή συμπεριφορά κατά τη διάρκεια της εκπαίδευσης.
- **Υπερβολική χωρητικότητα (256 νευρώνες):** Η αύξηση του αριθμού των νευρώνων δεν οδήγησε σε ουσιαστική βελτίωση της απόδοσης. Αντίθετα, το δίκτυο εμφάνισε αυξημένη αστάθεια κατά την εκπαίδευση, χωρίς να καταφέρει να παρουσιάσει σταθερή τάση σύγκλισης.



Σχήμα 2: Καμπύλη επιδόσεων για `hidden_size=128` (βέλτιστο μέγεθος)


3.4 Επίδραση Epsilon Decay

Epsilon Decay	Καλύτερο Σκορ	Μέσος Όρος	Last-20 Avg	Αξιολόγηση
100	52	12,1	15,20	Υπερβολικά γρήγορη εκμετάλλευση
300	453	66,9	119,9	Ισορροπημένη εξερεύνηση
600	223	31,3	170,3	Πιο αργή αλλά σταθερή εξερεύνηση

Η παράμετρος εξασθένησης του ϵ (epsilon decay) ρυθμίζει τη δυναμική μετάβαση του πράκτορα από τη φάση της τυχαίας εξερεύνησης (exploration) στη φάση της συστηματικής εκμετάλλευσης (exploitation) της αποκτηθείσας γνώσης. Η επιλογή του decay = 300 παρουσίασε την υψηλότερη κορυφαία επίδοση, επιτυγχάνοντας μέγιστη ανταμοιβή 453 και μέσο όρο τελευταίων 20 επεισοδίων ίσο με 119.9. Παράλληλα, η τιμή decay = 600 εμφάνισε πιο σταθερή συμπεριφορά στα τελευταία επεισόδια εκπαίδευσης, γεγονός που αναδεικνύει τη σημασία της σωστής χρονικής κλιμάκωσης της εξερεύνησης.

Η συγκριτική ανάλυση των τριών τιμών οδηγεί στα ακόλουθα συμπεράσματα:

- **Υπερβολικά γρήγορη εκμετάλλευση (decay = 100):** Η τιμή του ϵ μειώνεται απότομα, αναγκάζοντας τον πράκτορα να βασιστεί πολύ νωρίς σε ανεπαρκώς εκπαιδευμένα βάρη δικτύου. Λόγω έλλειψης επαρκούς εξερεύνησης του χώρου καταστάσεων, ο πράκτορας αδυνατεί να ανακαλύψει αποτελεσματικές στρατηγικές μακροχρόνιας ισορροπίας, με αποτέλεσμα η κορυφαία επίδοσή του να περιοριστεί στο σκορ 52.
- **Ισορροπημένη εξερεύνηση (decay = 300):** Η συγκεκριμένη τιμή επιτρέπει στον πράκτορα να εξερευνήσει επαρκώς το περιβάλλον κατά τα πρώτα επεισόδια εκπαίδευσης. Όπως παρατηρείται στο Σχήμα 3, μετά το επεισόδιο 230, όταν η γνώση έχει αρχίσει να σταθεροποιείται και το ϵ έχει μειωθεί σημαντικά, ο πράκτορας αρχίζει να αξιοποιεί αποτελεσματικότερα τις στρατηγικές που έχει μάθει, παρουσιάζοντας έντονη βελτίωση της ανταμοιβής και επιτυγχάνοντας μέγιστο σκορ 453.
- **Πολύ αργή εκμετάλλευση (decay = 600):** Η τιμή του ϵ παραμένει υψηλή για μεγαλύτερο χρονικό διάστημα, διατηρώντας αυξημένο βαθμό τυχαιότητας στις ενέργειες του πράκτορα. Αν και η διαδικασία εκμάθησης πραγματοποιείται πιο αργά, το μοντέλο παρουσιάζει μεγαλύτερη σταθερότητα στα τελευταία επεισόδια εκπαίδευσης, επιτυγχάνοντας μέσο όρο τελευταίων 20 επεισοδίων ίσο με 170.3.



Σχήμα 3: Καμπύλη επιδόσεων για $\text{decay} = 300$ (βέλτιστο epsilon decay)

4. Τελικό Μοντέλο

4.1 Σύγκριση Υπερπαραμέτρων (Φάση Πειραμάτων)

Κατά την προκαταρκτική φάση των 300 επεισοδίων, εξετάστηκε η επίδραση τριών κρίσιμων υπερπαραμέτρων στην ταχύτητα σύγκλισης και στη σταθερότητα του αλγορίθμου Double DQN: του ρυθμού μάθησης (Learning Rate), του μεγέθους των κρυφών επιπέδων (Hidden Size), και του ρυθμού μείωσης της παραμέτρου εξερεύνησης (Epsilon Decay).

- **Learning Rate (lr):** Οι δοκιμές με υψηλό ρυθμό μάθησης (10^{-2} και 10^{-3}) παρουσίασαν έντονη αστάθεια και αδυναμία σύγκλισης, καθώς οι διορθώσεις στα βάρη του δικτύου ήταν υπερβολικά επιθετικές, προκαλώντας ταλαντώσεις γύρω από το Reward 10-15. Αντίθετα, η τιμή $lr = 10^{-4}$ επέδειξε την πιο ομαλή και ελεγχόμενη συμπεριφορά, θέτοντας τις βάσεις για σταθερή μάθηση σε ορίζοντα περισσότερων επεισοδίων.
- **Hidden Size:** Η αρχιτεκτονική με 64 νευρώνες αποδείχθηκε περιορισμένης χωρητικότητας (underfitting) για την πλήρη αναπαράσταση των συσχετίσεων του χώρου κατάστασης. Η επιλογή των 256 νευρώνων, αν και ισχυρότερη υπολογιστικά, δεν οδήγησε σε ουσιαστική βελτίωση της απόδοσης κατά τα πρώτα 300 επεισόδια εκπαίδευσης. Η διαμόρφωση με 128 νευρώνες παρουσίασε οριακά καλύτερη και πιο σταθερή συμπεριφορά σε σχέση με τις υπόλοιπες αρχιτεκτονικές, προσφέροντας την καλύτερη ισορροπία μεταξύ εκφραστικότητας και υπολογιστικής πολυπλοκότητας.
- **Epsilon Decay:** Η χαμηλή τιμή (100) ανάγκασε τον πράκτορα να σταματήσει την εξερεύνηση πολύ νωρίς, παγιδεύοντάς τον σε φτωχές τοπικές πολιτικές. Η τιμή $decay = 300$ κρίθηκε ως η καταλληλότερη για το τελικό μοντέλο, καθώς προσέφερε την καλύτερη ισορροπία μεταξύ εξερεύνησης (exploration) και εκμετάλλευσης (exploitation) οδηγώντας στη σταθερότερη σύγκλιση και στη συνολικά καλύτερη απόδοση του μοντέλου.

4.2 Ανάλυση Σύγκλισης Τελικού Μοντέλου

Το τελικό μοντέλο εκπαιδεύτηκε για 800 επεισόδια ενσωματώνοντας τον βέλτιστο συνδυασμό υπερπαραμέτρων: $lr = 10^{-4}$, Hidden Size = 128, και Epsilon Decay = 300. Η καμπύλη μάθησης, όπως αποτυπώνεται στο τελικό διάγραμμα ανταμοιβών (Εικόνα 4.1), χωρίζεται σε τρεις διακριτές φάσεις μάθησης:

1. Φάση Έντονης Εξερεύνησης (Επεισόδια 0 – 400):

Στο πρώτο μισό της εκπαίδευσης, η συνολική ανταμοιβή ανά επεισόδιο παραμένει καθηλωμένη σε χαμηλά επίπεδα (περίπου 10–20 reward). Η συμπεριφορά αυτή είναι απόλυτα αναμενόμενη και οφείλεται στην επιλογή του υψηλού Epsilon Decay = 300. Ο πράκτορας επιλέγει κυρίως τυχαίες δράσεις, με σκοπό τη συλλογή πλούσιου και διαφοροποιημένου δείγματος εμπειριών. Η φάση αυτή είναι κρίσιμη, καθώς τροφοδοτεί τη μνήμη αναπαραγωγής (Replay Memory) με ένα ευρύ φάσμα καταστάσεων, αποτρέποντας τη χρονική συσχέτιση των δεδομένων εκπαίδευσης.

2. Φάση Εκθετικής Μάθησης και Άλματος Επίδοσης (Επεισόδια 410 – 500):

Μόλις η τιμή του epsilon μειωθεί επαρκώς, ο πράκτορας αρχίζει να βασίζεται όλο και περισσότερο στις προβλέψεις του δικτύου πολιτικής (Policy Network). Στο σημείο αυτό παρατηρείται μια απότομη μεταβολή της καμπύλης μάθησης, με τις ανταμοιβές να παρουσιάζουν σημαντική και σταθερή αύξηση μέσα σε μικρό αριθμό επεισοδίων. Η συμπεριφορά αυτή υποδεικνύει ότι η γνώση που αποθηκεύτηκε στη μνήμη κατά τα πρώτα

επεισόδια αρχίζει να αξιοποιείται αποτελεσματικά για τη διαμόρφωση μιας αποδοτικότερης πολιτικής ελέγχου.

3. Φάση Σταθεροποίησης και Υψηλής Επίδοσης (Επεισόδια 500 – 800):

Στο τελικό στάδιο, ο πράκτορας λειτουργεί κυρίως με βάση την εμπειρία που έχει αποκτήσει, καθώς η παράμετρος εξερεύνησης έχει προσεγγίσει την ελάχιστη τιμή της ($\epsilon = 0.05$). Η αρχιτεκτονική Double DQN παρουσιάζει σαφώς πιο σταθερή συμπεριφορά σε σχέση με τις αρχικές δοκιμές, με τον κινητό μέσο όρο (moving average) να διατηρείται σε αισθητά υψηλότερα επίπεδα σε σχέση με τα πρώτα στάδια της εκπαίδευσης. Παρά τις περιοδικές διακυμάνσεις της απόδοσης, το μοντέλο καταγράφει μέγιστη πειραματική ανταμοιβή 342 βημάτων, επιβεβαιώνοντας ότι ο πράκτορας έχει αναπτύξει αποτελεσματική πολιτική ελέγχου για το περιβάλλον CartPole-v1.


Η εξάλειψη των φαινομένων καταστροφικής λήθης (catastrophic forgetting) και η διατήρηση της σταθερότητας μέχρι το τελευταίο επεισόδιο υποδεικνύουν ότι η συγκεκριμένη τροποποίηση συνέβαλε σημαντικά στη σταθερότητα της εκπαίδευσης στον κώδικα: η έναρξη των ενημερώσεων του δικτύου-στόχου (Target Network Updates) αποκλειστικά μετά τη συμπλήρωση του ορίου $\text{MIN_REPLAY} = 1000$ προσέφερε στο σύστημα την απαραίτητη σταθερότητα, εμποδίζοντας την πρόωρη αναπροσαρμογή ασταθών βαρών.

Βασισμένοι στα αποτελέσματα των πειραμάτων, εκπαιδεύτηκε το τελικό μοντέλο με τις ακόλουθες βέλτιστες υπερπαραμέτρους για 800 επεισόδια:

Υπερπαραμέτρος	Τιμή	Αιτιολόγηση
Learning Rate	0.0001	Σταθερή σύγκλιση χωρίς αστάθεια
Hidden Size	128	Βέλτιστη ισορροπία πολυπλοκότητας
Epsilon Decay	300	Βασισμένο στην εκτενέστερη εκπαίδευση (800 ep.)
Batch Size	64	Σταθερή επιλογή για DQN
Gamma (γ)	0.99	Υψηλή εκτίμηση μελλοντικών ανταμοιβών
Memory Capacity	10.000	Επαρκής κάλυψη ιστορικού εμπειριών
Target Update	1.000 steps	Σταθερός στόχος εκπαίδευσης

4.3 Αποτελέσματα Τελικού Μοντέλου

Μετρική	Τιμή
Επεισόδια Εκπαίδευσης	800
Καλύτερο Σκορ Εκπαίδευσης	342
Μέσος Όρος Τελευταίων 20 Επεισοδίων	150,7 / 500
Μέσος Όρος Επίδειξης (5 επεισόδια)	218,8 / 500
Βέλτιστο Σκορ Επίδειξης	257 / 500
Ελάχιστο Σκορ Επίδειξης	183 / 500



Σχήμα 4: Καμπύλη εκπαίδευσης τελικού μοντέλου (800 επεισόδια)

Η εκπαίδευση του τελικού μοντέλου πραγματοποιήθηκε για **800 επεισόδια**. Όπως φαίνεται στο Σχήμα 4, η συμπεριφορά του πράκτορα (agent) δεν παρουσιάζει μια γραμμική βελτίωση, αλλά χωρίζεται σε διακριτές φάσεις μάθησης, οι οποίες αναλύονται παρακάτω:

1. **Φάση Εξερεύνησης (Episodes 0 – 280):** Στα πρώτα ~280 επεισόδια, το reward παραμένει σε πολύ χαμηλά επίπεδα (κοντά στο 10-20). Αυτό οφείλεται στην αρχική στρατηγική εξερεύνησης (ε-greedy), όπου η τιμή του ϵ είναι ακόμα υψηλή, αναγκάζοντας τον πράκτορα να εκτελεί κυρίως τυχαίες κινήσεις (exploration) για να μαζέψει εμπειρίες στο Replay Buffer, χωρίς να έχει αναπτύξει ακόμα μια σταθερή πολιτική (policy).
2. **Απότομη Μάθηση & Πρώτη Κορυφή (Episodes 280 – 350):** Μόλις ο πράκτορας συγκεντρώσει επαρκή δείγματα και το ϵ μειωθεί, παρατηρείται μια έντονη και απότομη άνοδος της απόδοσης. Ο κινητός μέσος όρος (Moving Average 20) αυξάνεται σημαντικά, ενώ το μοντέλο αρχίζει να επιτυγχάνει υψηλές ανταμοιβές άνω των 200 βημάτων. Η συμπεριφορά αυτή υποδεικνύει ότι το δίκτυο έχει αρχίσει να κατανοεί αποτελεσματικά τη δυναμική του περιβάλλοντος CartPole.
3. **Φαινόμενο Κατάρρευσης της Πολιτικής (Episodes 350 – 570):** Μετά το επεισόδιο 350, παρατηρείται μια σταδιακή αλλά συνεχή πτώση της απόδοσης, η οποία κορυφώνεται με μια απότομη κατάρρευση (drop) γύρω στο επεισόδιο 550, όπου το Moving Average παρουσιάζει αισθητή μείωση και αυξημένη αστάθεια.
 - ο **Ερμηνεία:** Παρόμοια φαινόμενα αστάθειας έχουν παρατηρηθεί συχνά σε αλγόριθμους της οικογένειας DQN, ακόμη και σε παραλλαγές όπως το Double DQN. Μπορεί να οφείλεται σε catastrophic forgetting (το δίκτυο προσαρμόζεται υπερβολικά σε πρόσφατες εμπειρίες του Replay Buffer, μειώνοντας την ικανότητά του να γενικεύει σε πιο ακραίες καταστάσεις) ή σε overestimation bias των Q-

values που συσσωρεύεται με τον χρόνο, οδηγώντας το δίκτυο σε υποβέλτιστες (suboptimal) αποφάσεις.

4. **Ανάκαμψη & Σταθεροποίηση (Episodes 570 – 800):** Μετά το επεισόδιο 570, ο πράκτορας ανακτά σταδιακά τη σταθερότητα της πολιτικής του, πιθανώς επειδή το Replay Buffer εμπλουτίζεται ξανά με πιο αντιπροσωπευτικά δείγματα εμπειρίας. Η απόδοση αυξάνεται εκ νέου με σχετικά σταθερό ρυθμό, με τον κινητό μέσο όρο να σταθεροποιείται στην περιοχή του 150.7 στα τελευταία 20 επεισόδια. Κατά τη διάρκεια αυτής της φάσης, το μοντέλο κατέγραψε μέγιστη ανταμοιβή 342 βημάτων.

4.4 Αξιολόγηση Μοντέλου (Demonstration Results)

Κατά τη φάση της επίδειξης (testing) σε 5 ανεξάρτητα επεισόδια, όπου η εξερεύνηση είχε απενεργοποιηθεί πλήρως ($\epsilon = 0$), το μοντέλο παρουσίασε σταθερή και συνεπή συμπεριφορά. Ο μέσος όρος επίδειξης ανήλθε σε 218.8 / 500, με το βέλτιστο σκορ να φτάνει τα 257 και το ελάχιστο τα 183. Παρά τη στοχαστικότητα του περιβάλλοντος CartPole-v1, η σχετικά μικρή διακύμανση μεταξύ των επεισοδίων υποδεικνύει ότι ο πράκτορας έχει αναπτύξει μια αξιόπιστη πολιτική ελέγχου και είναι σε θέση να διατηρεί την ισορροπία του συστήματος για σημαντικό χρονικό διάστημα.

5. Οδηγίες Εκτέλεσης

5.1 Απαιτήσεις Συστήματος

Βιβλιοθήκη	Έκδοση	Χρήση
Python	3.10+	Βασική γλώσσα προγραμματισμού
PyTorch	2.0+	Νευρωνικά δίκτυα και εκπαίδευση
Gymnasium	0.29+	Περιβάλλον CartPole-v1
NumPy	1.24+	Αριθμητικές πράξεις
Matplotlib	3.7+	Οπτικοποίηση αποτελεσμάτων
Pygame	2.0+	Απεικόνιση (play.py)

5.2 Αναπαραγωγιμότητα Πειραμάτων

Για τη διασφάλιση της αναπαραγωγιμότητας (reproducibility) των πειραμάτων χρησιμοποιήθηκαν σταθεροί τυχαίοι σπόροι (random seeds) στις βασικές βιβλιοθήκες της Python, NumPy και PyTorch.

Παράδειγμα αρχικοποίησης:

- `random.seed(42)`
- `np.random.seed(42)`
- `torch.manual_seed(42)`

Η χρήση σταθερών seeds μειώνει τη στοχαστική μεταβλητότητα της εκπαίδευσης και διευκολύνει τη συνεπή αξιολόγηση των υπερπαραμέτρων.

5.3 Εγκατάσταση

Η εγκατάσταση όλων των απαραίτητων πακέτων και των εξαρτήσεών τους (dependencies) για το περιβάλλον ελέγχου γίνεται μέσω του διαχειριστή πακέτων `pip` με την ακόλουθη εντολή:

`pip install torch gymnasium[classic-control] numpy matplotlib pandas pygame`

5.4 Εκτέλεση Εκπαίδευσης

Για την εκτέλεση του συνόλου των πειραμάτων και την εκπαίδευση του τελικού μοντέλου, χρησιμοποιείται το κεντρικό αρχείο εισόδου: `python main.py`

Τα αποτελέσματα της εκπαίδευσης, τα διαγράμματα και τα βάρη των δικτύων αποθηκεύονται αυτόματα στον κατάλογο `results_cartpole_dqn/`. Η οργανωτική δομή των αρχείων εξόδου διαμορφώνεται ως εξής:

```

results_cartpole_dqn/
├── lr/           # Αποτελέσματα δοκιμών για το Learning Rate
├── hidden/       # Αποτελέσματα δοκιμών για τα κρυφά επίπεδα
├── eps/         # Αποτελέσματα δοκιμών για το Epsilon Decay
├── final_model/  # Αρχεία τελικού βέλτιστου μοντέλου
│   ├── best_model.pth # Τα βάρη του δικτύου με το υψηλότερο σκορ
│   ├── last_model.pth # Τα βάρη του δικτύου στο τελευταίο επεισόδιο
│   ├── rewards.png   # Η γραφική παράσταση της καμπύλης μάθησης
│   └── rewards.csv   # Το ιστορικό των επιβραβεύσεων ανά επεισόδιο

```

Κάθε υποφάκελος των δοκιμών περιέχει αντίστοιχα τα αρχεία `best_model.pth`, `last_model.pth`, `rewards.png` και `rewards.csv` για την αξιολόγηση της εκάστοτε υπερπαραμέτρου.

5.5 Εκτέλεση Επίδειξης

Αφού ολοκληρωθεί επιτυχώς η εκπαίδευση, η αξιολόγηση και η οπτικοποίηση της τελικής συμπεριφοράς του πράκτορα σε περιβάλλον rendering πραγματοποιείται εκτελώντας:

```
python play.py
```

Το συγκεκριμένο script φορτώνει αυτόματα τα αποθηκευμένα βάρη του βέλτιστου μοντέλου (`best_model.pth`) από τον φάκελο `final_model/`, απενεργοποιεί τη στοχαστική εξερεύνηση (`epsilon = 0`) και ανοίγει ένα παράθυρο γραφικής απεικόνισης (μέσω του μηχανισμού rendering του Gymnasium). Η διαδικασία εκτελείται για 5 ανεξάρτητα επεισόδια και οι συνολικές ανταμοιβές (total rewards) εκτυπώνονται σε πραγματικό χρόνο στην κονσόλα.

6. Συμπεράσματα

Στην παρούσα εργασία υλοποιήθηκε και αξιολογήθηκε ένας πράκτορας βασισμένος στον αλγόριθμο **Double Deep Q-Network (Double DQN)** για την επίλυση του προβλήματος ελέγχου **CartPole-v1**. Μέσα από την εκτενή πειραματική διαδικασία και τη διερεύνηση διαφορετικών υπερπαραμέτρων, εξήχθησαν τα ακόλουθα βασικά συμπεράσματα:

Παράμετρος	Βέλτιστη Τιμή	Παρατήρηση
Learning Rate	0.0001	Εξασφάλιση αργής αλλά εξαιρετικά σταθερής σύγκλισης, αποφεύγοντας τις έντονες αποκλίσεις.
Hidden Size	128	Οριακά καλύτερη και πιο σταθερή συμπεριφορά σε σχέση με τις υπόλοιπες διαμορφώσεις
Epsilon Decay	300	Παρουσίασε την υψηλότερη κορυφαία επίδοση και ισορροπημένη μετάβαση από exploration σε exploitation

Το τελικό μοντέλο επέδειξε σταθερή και αξιόπιστη απόδοση, επιτυγχάνοντας μέσο σκορ **218,8 / 500** κατά τη φάση της επίδειξης (demonstration), γεγονός που επιβεβαιώνει την αποτελεσματικότητα του προτεινόμενου αλγορίθμου. Η ενσωμάτωση προηγμένων τεχνικών σταθεροποίησης, όπως η αρχιτεκτονική **Double DQN** (για τον περιορισμό του overestimation bias), ο μηχανισμός **Experience Replay** (για τη διακοπή της χρονικής συσχέτισης των δειγμάτων), η χρήση **Target Network** (για τη διατήρηση σταθερών στόχων κατά την εκπαίδευση)

και το **Gradient Clipping** (για την αποφυγή του προβλήματος των exploding gradients), συνέβαλαν καθοριστικά στη γενικότερη σταθερότητα της εκπαιδευτικής διαδικασίας και στη βελτίωση της σταθερότητας και της συνολικής απόδοσης του μοντέλου.

6.1 Περιορισμοί της Προσέγγισης

Παρότι το τελικό μοντέλο επέδειξε ικανοποιητική σταθερότητα και απόδοση στο περιβάλλον CartPole-v1, η παρούσα εργασία παρουσιάζει ορισμένους περιορισμούς.

Αρχικά, το CartPole-v1 αποτελεί ένα σχετικά απλό πρόβλημα βαθιάς ενισχυτικής μάθησης με χαμηλοδιάστατο χώρο καταστάσεων και διακριτό χώρο δράσεων. Επομένως, τα αποτελέσματα δεν μπορούν να γενικευτούν άμεσα σε πιο σύνθετα περιβάλλοντα με υψηλή διαστατικότητα ή συνεχή χώρο ενεργειών.

Επιπλέον, η αξιολόγηση πραγματοποιήθηκε σε ένα μόνο περιβάλλον και χωρίς εκτεταμένη στατιστική ανάλυση πολλαπλών τυχαίων αρχικοποιήσεων (random seeds). Ως εκ τούτου, ενδέχεται να υπάρχει κάποια εξάρτηση των αποτελεσμάτων από τη στοχαστικότητα της διαδικασίας εκπαίδευσης.

Τέλος, αν και η αρχιτεκτονική Double DQN βελτίωσε σημαντικά τη σταθερότητα της μάθησης, παρατηρήθηκαν φαινόμενα προσωρινής κατάρρευσης της πολιτικής (policy collapse), γεγονός που υποδεικνύει ότι η εκπαίδευση αλγορίθμων βαθιάς ενισχυτικής μάθησης παραμένει μια απαιτητική διαδικασία με σημαντικές προκλήσεις σταθερότητας.

7. Βιβλιογραφία

- Lapan, M. (2020). *Deep Reinforcement Learning Hands-On* (2nd ed.). Packt Publishing.
- Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning: An Introduction* (2nd ed.). MIT Press.
- Mnih, V., Kavukcuoglu, K., Silver, D., Rusu, A. A., Veness, J., Bellemare, M. G., et al. (2015). *Human-level control through deep reinforcement learning*. *Nature*, 518(7540), 529–533.
- Van Hasselt, H., Guez, A., & Silver, D. (2016). *Deep Reinforcement Learning with Double Q-learning*. *Proceedings of the AAAI Conference on Artificial Intelligence*, 30(1), 2094–2100.
- Gymnasium Documentation. Farama Foundation.
<https://gymnasium.farama.org/>
- PyTorch Documentation.
<https://pytorch.org/docs/stable/index.html>